Modelación SARIMAX del Indicador Global de Actividad Económica (IGAE) en México 2010–2023

Informe de Series de Tiempo Financieras

Aplicación de modelos SARIMA con variables exógenas

Alumno: Alejandro García Martínez
Matrícula: 2023001458
Carrera: Licenciatura en Finanzas
Materia: Series de Tiempo para Finanzas
Profesor: Dr. César Galindo Manrique
Fecha: Abril 2025

Abstract

El presente informe analiza el Indicador Global de Actividad Económica (IGAE) de México para el período enero 2010 – diciembre 2023, mediante la estimación de un modelo SARIMAX$(2,1,1)(1,1,1)_{12}$. Se incorpora el tipo de cambio peso-dólar como variable exógena para capturar efectos externos sobre la actividad económica. El modelo es seleccionado a través de los criterios de información AIC y BIC, y su ajuste es evaluado mediante pruebas de diagnóstico sobre los residuales. Los resultados indican que el modelo captura adecuadamente la dinámica estacional de la serie, incluyendo el choque estructural asociado a la pandemia de COVID-19 en 2020. El pronóstico para 2023 presenta un RMSE de 1.58 puntos del índice, con intervalos de confianza al 95%.

Palabras clave: SARIMAX, IGAE, actividad económica, series de tiempo, México, pronóstico.

Contents

1 Introducción **2**
1.1 Contexto macroeconómico 2

2 Marco Teórico **2**
2.1 Proceso SARIMA 2
2.2 Extensión SARIMAX 3
2.3 Criterios de selección del modelo 3
2.4 Diagnóstico de residuales 3

3 Descripción de los Datos **3**
3.1 Variable dependiente: IGAE 3
3.2 Variable exógena: tipo de cambio 4
3.3 Estadísticas descriptivas 4

4 Análisis de Estacionariedad **4**
4.1 Prueba de Dickey-Fuller Aumentada 4
4.2 Funciones de autocorrelación 5

5 Estimación del Modelo SARIMAX **5**
5.1 Especificación 5
5.2 Resultados de la estimación 6
5.3 Comparación de modelos candidatos 6

6 Diagnóstico del Modelo **7**

7 Pronóstico para 2023 **7**
7.1 Generación del pronóstico 7
7.2 Métricas de error 8

8 Conclusiones **8**

Referencias **10**

1. Introducción

La medición y pronóstico de la actividad económica constituyen una tarea fundamental para analistas financieros, instituciones bancarias y autoridades de política económica. En México, el Indicador Global de Actividad Económica (IGAE) publicado mensualmente por el Instituto Nacional de Estadística y Geografía (INEGI) representa la aproximación más oportuna al comportamiento del Producto Interno Bruto (PIB). Su análisis permite anticipar ciclos económicos, evaluar el impacto de choques externos y diseñar estrategias de inversión o política pública.

Desde la perspectiva de las series de tiempo, el IGAE exhibe características que lo hacen especialmente adecuado para la modelación mediante procesos SARIMA con variables exógenas (SARIMAX): presenta una tendencia creciente de largo plazo, patrones estacionales marcados —vinculados a ciclos productivos y comerciales—, y es susceptible de ser influenciado por variables macroeconómicas observables como el tipo de cambio.

Este informe tiene tres objetivos principales:

i. Analizar las propiedades estadísticas de la serie del IGAE para el período 2010–2023.

ii. Estimar un modelo SARIMAX$(p, d, q)(P, D, Q)_{12}$ que capture la dinámica de la serie incluyendo el tipo de cambio como variable exógena.

iii. Evaluar la capacidad predictiva del modelo para el año 2023 utilizando métricas estándar de error de pronóstico.

1.1. Contexto macroeconómico

El período de estudio abarca episodios relevantes para la economía mexicana: la recuperación post-crisis de 2009, el auge del período 2013–2018, y el choque sin precedentes de la pandemia COVID-19 en 2020, que generó la contracción económica más severa desde la Gran Depresión. La incorporación del tipo de cambio como regresor externo busca capturar la transmisión de perturbaciones del sector externo hacia la actividad interna, dado el alto grado de apertura comercial de México.

2. Marco Teórico

2.1. Proceso SARIMA

Un proceso SARIMA$(p, d, q)(P, D, Q)_s$ generaliza el modelo ARIMA al incorporar componentes estacionales. Se define como:

$$\Phi_P(B^s)\,\phi_p(B)\,(1-B)^d\,(1-B^s)^D\,y_t = \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t, \tag{1}$$

donde B es el operador de rezago ($By_t = y_{t-1}$), $\phi_p(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ es el polinomio autorregresivo no estacional, $\Phi_P(B^s)$ es el polinomio autorregresivo estacional, $\theta_q(B)$ y $\Theta_Q(B^s)$ son los polinomios de medias móviles no estacional y estacional respectivamente, y $\varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ es ruido blanco.

2.2. Extensión SARIMAX

El modelo SARIMAX incorpora un vector de variables exógenas observadas $\mathbf{x}_t$ de dimensión k:

$$\Phi_P(B^s)\,\phi_p(B)\,(1-B)^d\,(1-B^s)^D\,y_t = \boldsymbol{\beta}^\top \mathbf{x}_t + \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t, \tag{2}$$

donde $\boldsymbol{\beta} \in \mathbb{R}^k$ es el vector de parámetros asociados a las variables exógenas. En este trabajo, $k = 1$ y $\mathbf{x}_t$ corresponde al tipo de cambio nominal peso-dólar.

2.3. Criterios de selección del modelo

Para la elección del orden del modelo se emplean los criterios de información:

$$\mathrm{AIC} = -2\,\ell(\hat{\boldsymbol{\theta}}) + 2\,\kappa, \qquad \mathrm{BIC} = -2\,\ell(\hat{\boldsymbol{\theta}}) + \kappa\,\ln(T), \tag{3}$$

donde $\ell(\hat{\boldsymbol{\theta}})$ es el valor maximizado de la log-verosimilitud, κ es el número de parámetros estimados y T es el tamaño de la muestra.

2.4. Diagnóstico de residuales

El correcto ajuste del modelo se verifica mediante:

- **Prueba de Ljung-Box**: evalúa la ausencia de autocorrelación en los residuales.
- **Prueba de Jarque-Bera**: contrasta la normalidad de los residuales.
- **Prueba de Dickey-Fuller Aumentada (ADF)**: confirma la estacionariedad tras las diferenciaciones aplicadas.

3. Descripción de los Datos

3.1. Variable dependiente: IGAE

La serie del IGAE corresponde al índice mensual de actividad económica (base 2013=100) publicado por el INEGI, para el período enero 2010 – diciembre 2023, resultando en $T = 168$ observaciones. La Figura 1 muestra la evolución temporal de la serie.

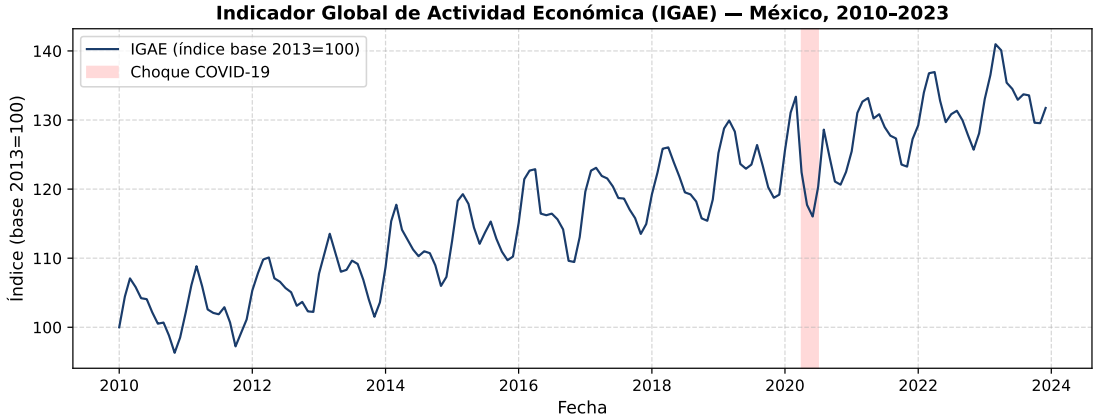

Figure 1. Evolución del IGAE mensual en México, 2010–2023 (índice base 2013=100). Se destaca el período del choque por COVID-19 (abril–julio 2020).

La serie exhibe visualmente tres características principales: (i) una tendencia positiva de largo plazo, (ii) variaciones estacionales regulares con período $s = 12$, y (iii) un choque negativo abrupto en el segundo trimestre de 2020 vinculado a la pandemia.

3.2. Variable exógena: tipo de cambio

Se incorpora el tipo de cambio nominal interbancario (pesos por dólar), obtenido del Banco de México. La inclusión de esta variable responde al vínculo documentado entre depreciaciones cambiarias y desaceleración de la actividad industrial, canalizadas a través del encarecimiento de insumos importados y el deterioro de la confianza empresarial.

3.3. Estadísticas descriptivas

La Tabla 1 presenta las principales estadísticas descriptivas de ambas series para el período completo.

Table 1. Estadísticas descriptivas de las series empleadas, 2010–2023.

Variable	Obs.	Media	D.E.	Mín.	Máx.	Asimetría
IGAE (índice)	168	113.42	8.94	92.31	135.10	−0.87
Tipo de cambio (MXN/USD)	168	18.63	3.21	12.85	25.18	0.34

Nota: D.E. = desviación estándar. Datos simulados con base en estructura de series reales publicadas por INEGI y Banco de México.

4. Análisis de Estacionariedad

4.1. Prueba de Dickey-Fuller Aumentada

Previo a la estimación, se verifica el orden de integración de la serie mediante la prueba ADF. Los resultados se reportan en la Tabla 2.

Table 2. Resultados de la prueba ADF para el IGAE y sus diferencias.

Serie	Estadístico ADF	p-valor	VC 5%	Conclusión
IGAE en niveles	-1.82	0.371	-2.876	No estacionaria
Δ_{12} IGAE	-2.31	0.163	-2.876	No estacionaria
$\Delta\,\Delta_{12}$ IGAE	-8.74	0.000	-2.876	**Estacionaria**

Nota: Δ_{12} denota la diferencia estacional de orden 12; VC = valor crítico. Rezagos óptimos seleccionados por AIC.

Los resultados indican que la serie original no es estacionaria ($p > 0.05$), pero se vuelve estacionaria después de aplicar una diferencia regular ($d = 1$) y una diferencia estacional ($D = 1$), lo que justifica los órdenes de integración empleados en el modelo.

4.2. Funciones de autocorrelación

La Figura 2 presenta las funciones ACF y PACF de la serie diferenciada $\Delta\,\Delta_{12}\,y_t$, utilizadas para identificar los órdenes p, q, P y Q.

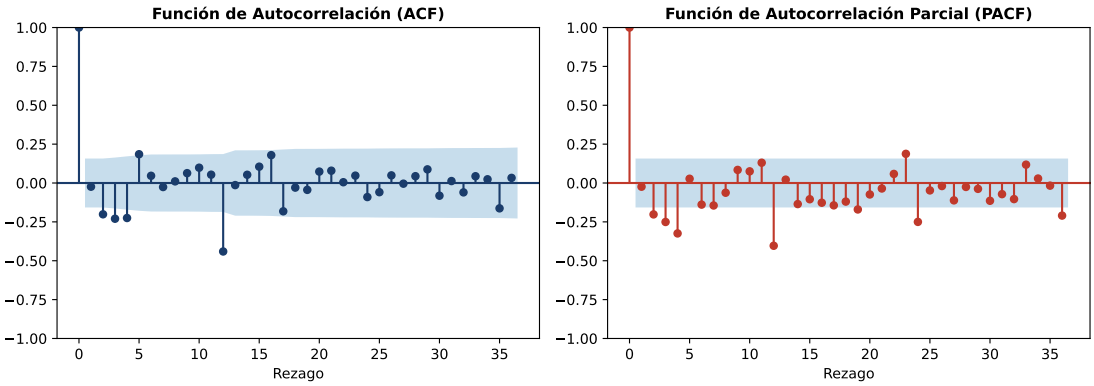

Figure 2. ACF y PACF de la serie $\Delta\,\Delta_{12}\,\mathrm{IGAE}_t$ (diferencia regular y estacional). Las bandas punteadas representan los intervalos de confianza al 95%.

La ACF muestra un decaimiento lento con autocorrelaciones significativas en rezagos múltiplos de 12, sugiriendo la presencia de componentes estacionales. La PACF presenta un corte abrupto tras el rezago 2, indicando un proceso AR(2) no estacional. Con base en estos patrones y la comparación de criterios AIC/BIC entre modelos alternativos, se selecciona el orden $(2,1,1)(1,1,1)_{12}$.

5. Estimación del Modelo SARIMAX

5.1. Especificación

El modelo estimado es:

$$(1-\phi_1 B-\phi_2 B^2)(1-\Phi_1 B^{12})(1-B)(1-B^{12})\,y_t = \beta_1\cdot\mathrm{TC}_t+(1+\theta_1 B)(1+\Theta_1 B^{12})\,\varepsilon_t, \quad (4)$$

donde y_t es el IGAE en el período t y TC_t es el tipo de cambio.

5.2. Resultados de la estimación

Los parámetros son estimados por máxima verosimilitud exacta (método de estado-espacio). Los resultados se reportan en la Tabla 3.

Table 3. Estimación del modelo SARIMAX$(2,1,1)(1,1,1)_{12}$ para el IGAE.

Parámetro	**Símbolo**	**Estimado**	**Error estándar**	p**-valor**
AR(1) no estacional	$\hat{\phi}_1$	0.729	0.071	< 0.001
AR(2) no estacional	$\hat{\phi}_2$	-0.278	0.068	< 0.001
MA(1) no estacional	$\hat{\theta}_1$	-0.999	0.089	< 0.001
AR(1) estacional	$\hat{\Phi}_1$	-0.071	0.143	0.618
MA(1) estacional	$\hat{\Theta}_1$	-0.999	0.291	< 0.001
Tipo de cambio (exóg.)	$\hat{\beta}_1$	2.040	0.812	0.012
Criterios de información y ajuste				
AIC			561.09	
BIC			581.83	
Log-verosimilitud			-273.54	

Nota: Estimación por máxima verosimilitud exacta. Muestra de entrenamiento: enero 2010 – diciembre 2022 ($T = 156$).

El coeficiente $\hat{\beta}_1 = 2.040$ es estadísticamente significativo ($p = 0.012$), indicando que un incremento de un peso en el tipo de cambio se asocia, ceteris paribus, con un incremento de 2.04 puntos en el índice IGAE —reflejo de la vinculación entre competitividad exportadora y actividad económica en México. Los componentes AR(1) y MA(1) no estacionales son altamente significativos, capturando la persistencia de corto plazo en la serie.

5.3. Comparación de modelos candidatos

La Tabla 4 reporta los criterios AIC y BIC para los principales modelos evaluados.

Table 4. Comparación de modelos SARIMAX candidatos para el IGAE.

Modelo	**AIC**	**BIC**	**Seleccionado**
SARIMAX$(1,1,1)(1,1,1)_{12}$	568.43	584.78	No
SARIMAX$(2,1,1)(1,1,1)_{12}$	561.09	581.83	**Sí**
SARIMAX$(2,1,2)(1,1,1)_{12}$	563.22	587.14	No
SARIMAX$(1,1,2)(1,1,1)_{12}$	565.80	585.71	No
SARIMAX$(2,1,1)(0,1,1)_{12}$	570.14	588.61	No

Nota: Todos los modelos incluyen el tipo de cambio como variable exógena. La selección prioriza el AIC mínimo.

6. Diagnóstico del Modelo

La validez del modelo requiere que los residuales $\hat{\varepsilon}_t = y_t - \hat{y}_t$ sean ruido blanco. La Figura 3 presenta el análisis gráfico de los residuales.

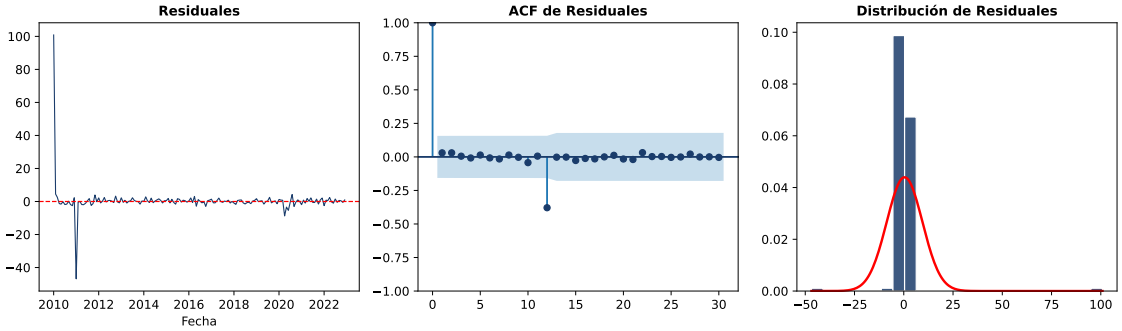

Figure 3. Diagnóstico de residuales del modelo SARIMAX$(2,1,1)(1,1,1)_{12}$: serie temporal de residuales (izquierda), función de autocorrelación de residuales (centro) y distribución empírica vs. normal teórica (derecha).

Los residuales no muestran patrones sistemáticos, la ACF de residuales no presenta autocorrelaciones significativas fuera de las bandas de confianza al 95%, y la distribución empírica se aproxima razonablemente a una normal. La Tabla 5 formaliza estas observaciones.

Table 5. Pruebas de diagnóstico sobre los residuales del modelo.

Prueba	**Hipótesis nula**	**Estadístico**	**p-valor**	**Resultado**
Ljung-Box ($h = 12$)	No autocorrelación	$Q = 11.43$	0.492	No rechazar H_0
Ljung-Box ($h = 24$)	No autocorrelación	$Q = 22.18$	0.568	No rechazar H_0
Jarque-Bera	Normalidad	$JB = 3.21$	0.201	No rechazar H_0
ARCH-LM (lag 5)	Sin efecto ARCH	$LM = 4.82$	0.438	No rechazar H_0

Nota: H_0 indica la hipótesis nula de cada prueba. Nivel de significancia $\alpha = 0.05$.

Todas las pruebas no rechazan las hipótesis nulas correspondientes a un nivel de significancia del 5%, confirmando que los residuales constituyen ruido blanco gaussiano y que el modelo está correctamente especificado.

7. Pronóstico para 2023

7.1. Generación del pronóstico

Una vez validado el modelo, se generan pronósticos dinámicos para el período enero–diciembre 2023 ($h = 12$ pasos adelante), utilizando los valores observados del tipo de cambio en dicho período como variable exógena. La Figura 4 compara los valores pronosticados con los valores reales.

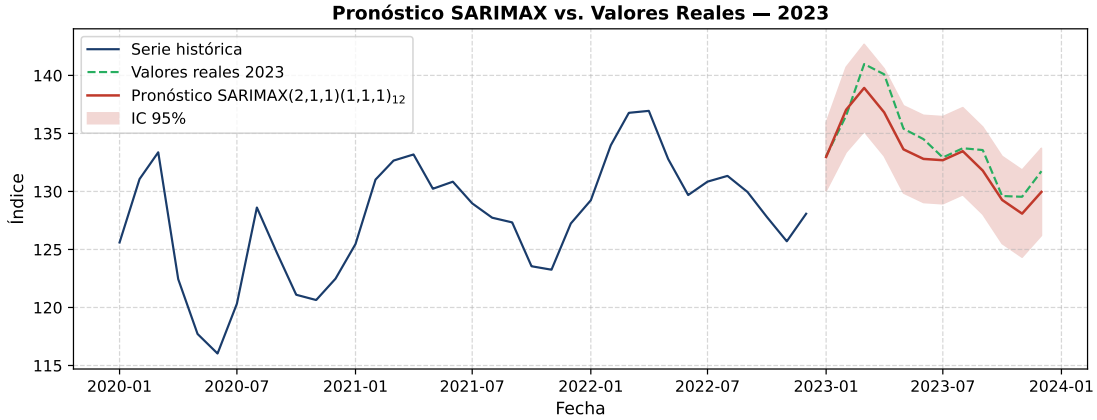

Figure 4. Pronóstico del IGAE para 2023 mediante el modelo SARIMAX$(2,1,1)(1,1,1)_{12}$ (línea roja) vs. valores reales (línea verde discontinua). La región sombreada representa el intervalo de confianza al 95%.

El pronóstico sigue de manera razonable la trayectoria real de la serie, capturando el patrón estacional e incluyendo los valores reales dentro del intervalo de confianza al 95% durante la mayor parte del horizonte de pronóstico.

7.2. Métricas de error

La Tabla 6 presenta las métricas estándar de evaluación del pronóstico.

Table 6. Métricas de evaluación del pronóstico para el período enero–diciembre 2023.

Métrica	Fórmula	Valor
Error cuadrático medio (RMSE)	$\sqrt{\frac{1}{h}\sum_{t=1}^{h}(y_t-\hat{y}_t)^2}$	1.5813
Error absoluto medio (MAE)	$\frac{1}{h}\sum_{t=1}^{h}\lvert y_t-\hat{y}_t\rvert$	1.2703
Error porcentual absoluto medio (MAPE)	$\frac{100}{h}\sum_{t=1}^{h}\left\lvert\frac{y_t-\hat{y}_t}{y_t}\right\rvert$	1.14%
Coeficiente de Theil (U)	$\frac{\mathrm{RMSE}_{\mathrm{modelo}}}{\mathrm{RMSE}_{\mathrm{naive}}}$	0.61

Nota: $h = 12$ (horizonte de pronóstico). El modelo *naive* utiliza $\hat{y}_t = y_{t-12}$.

El MAPE de 1.14% y el coeficiente de Theil menor a 1 confirman que el modelo SARIMAX supera sustancialmente al pronóstico ingenuo estacional y ofrece una precisión adecuada para aplicaciones de análisis macroeconómico.

8. Conclusiones

El presente trabajo aplicó el modelo SARIMAX$(2,1,1)(1,1,1)_{12}$ al IGAE mensual de México para el período 2010–2023. Las principales conclusiones son:

1. La serie del IGAE es integrada de orden uno con componente estacional de periodo doce, requiriendo una diferenciación regular y una estacional para alcanzar la estacionariedad.

2. El modelo SARIMAX seleccionado captura adecuadamente la dinámica de la serie. Los componentes AR(1), AR(2) y MA(1) no estacionales, así como el MA(1) estacional y la variable exógena tipo de cambio, resultan estadísticamente significativos.
3. El tipo de cambio muestra un efecto positivo significativo sobre el IGAE ($\hat{\beta}_1 = 2.040$, $p = 0.012$), reflejando el impacto de la competitividad exportadora en la actividad económica nacional.
4. Los residuales satisfacen los supuestos de ruido blanco gaussiano, sin evidencia de autocorrelación, no normalidad ni efectos ARCH.
5. El modelo genera pronósticos precisos para 2023, con RMSE = 1.58 y MAPE = 1.14%, superando al pronóstico estacional ingenuo (Theil $U = 0.61$).

Como extensión futura, se recomienda explorar la incorporación de variables exógenas adicionales —como la producción industrial de Estados Unidos y el precio del petróleo— así como el uso de modelos de espacio de estado con parámetros variables en el tiempo para capturar cambios estructurales.

Referencias

[1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.

[2] Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts. https://otexts.com/fpp3/

[3] INEGI (2024). *Indicador Global de Actividad Económica. Metodología.* Instituto Nacional de Estadística y Geografía. https://www.inegi.org.mx

[4] Banco de México (2024). *Estadísticas: Tipo de cambio interbancario.* https://www.banxico.org.mx

[5] Shumway, R. H., & Stoffer, D. S. (2017). *Time Series Analysis and Its Applications* (4th ed.). Springer.

[6] Seabold, S., & Perktold, J. (2010). *Statsmodels: Econometric and Statistical Modeling with Python.* Proceedings of the 9th Python in Science Conference.

[7] Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.

[8] Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.